Ismael Soilet
@ismaelsoilet

POR QUE A IA INVENTA COISAS SOBRE OS SEUS DADOS?

Você entregou seus PDFs à IA e ela ainda **alucinou?** Entenda o salto do **RAG** clássico para o **GraphRAG** e o **Context Engineering** — e por que **70% a 80%** dos projetos travam antes da produção



Ismael Soilet
@ismaelsoilet

DO PILOTO AO CAOS: 70% A 80% DOS PROJETOS TRAVAM

- **ILUSÃO DA DEMO:** Com 5 PDFs limpos no laboratório, a resposta **parece mágica.**
- **MUNDO REAL:** Bases reais têm arquivos velhos, **sigilosos e conflitantes.**
- **REGRA DURA:** A qualidade do contexto é **multiplicativa** — falhou uma etapa, a IA inventa.



Ismael Soilet
@ismaelsoilet

A 'MALDIÇÃO DO MEIO': 1 MILHÃO DE TOKENS NÃO SALVA

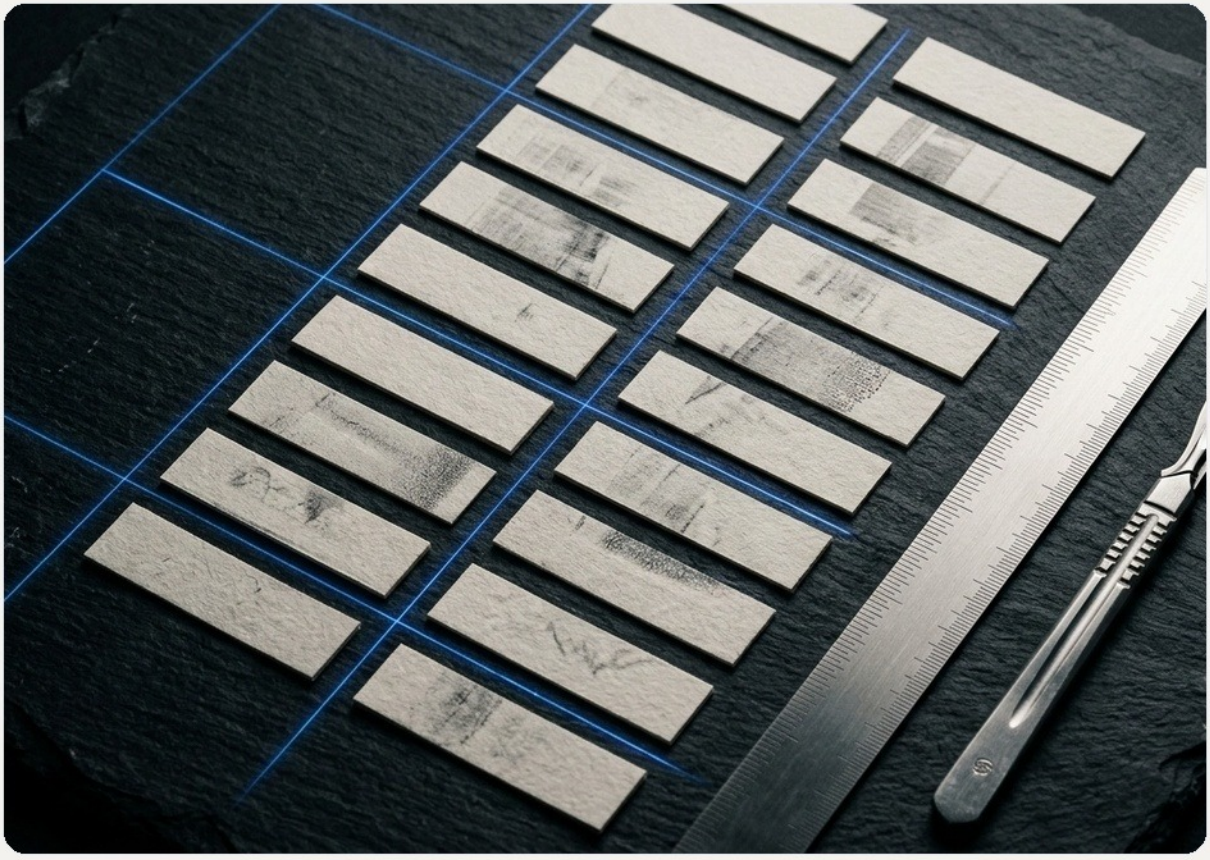
- **CURVA EM U:** Estudos (Stanford/UC Berkeley) provam que LLMs **ignoram o meio** de textos longos.
- **CONTEXT ROT:** Quanto mais páginas soltas no prompt, mais a **atenção se dilui.**
- **CONTRADIÇÃO:** A resposta certa entra na janela, mas fica **invisível no meio do ruído.**



Ismael Soilet
@ismaelsoilet

O QUE É RAG? O MÉTODO DE 'FATIAR LIVROS'

- **BUSCA VETORIAL:** Recorta PDFs em **blocos de texto** (chunks) e cria vetores numéricos.
- **ONDE BRILHA:** Perguntas diretas e pontuais por **custo mínimo** (< 1.000 tokens).
- **LIMITE CRÍTICO:** Semelhança de palavras **não enxerga relações,** vigência nem hierarquia.



Ismael Soilet
@ismaelsoilet

OS 3 PECADOS QUE QUEBRAM O RAG EM EMPRESAS

- **DADO VELHO:** Norma revogada com palavras parecidas **vence a regra nova** (Stale Docs).
- **CHOQUE DE FONTES:** Área A diz **5 dias** e Área B diz **10** — a IA mistura e alucina.
- **VAZAMENTO DE ACESSO:** Filtrar só no fim é tarde — o LLM **já leu o sigilo** (ACL Drift)!



Ismael Soilet
@ismaelsoilet

MATRIZ DE VERDADE: RAG E JANELAS GIGANTES

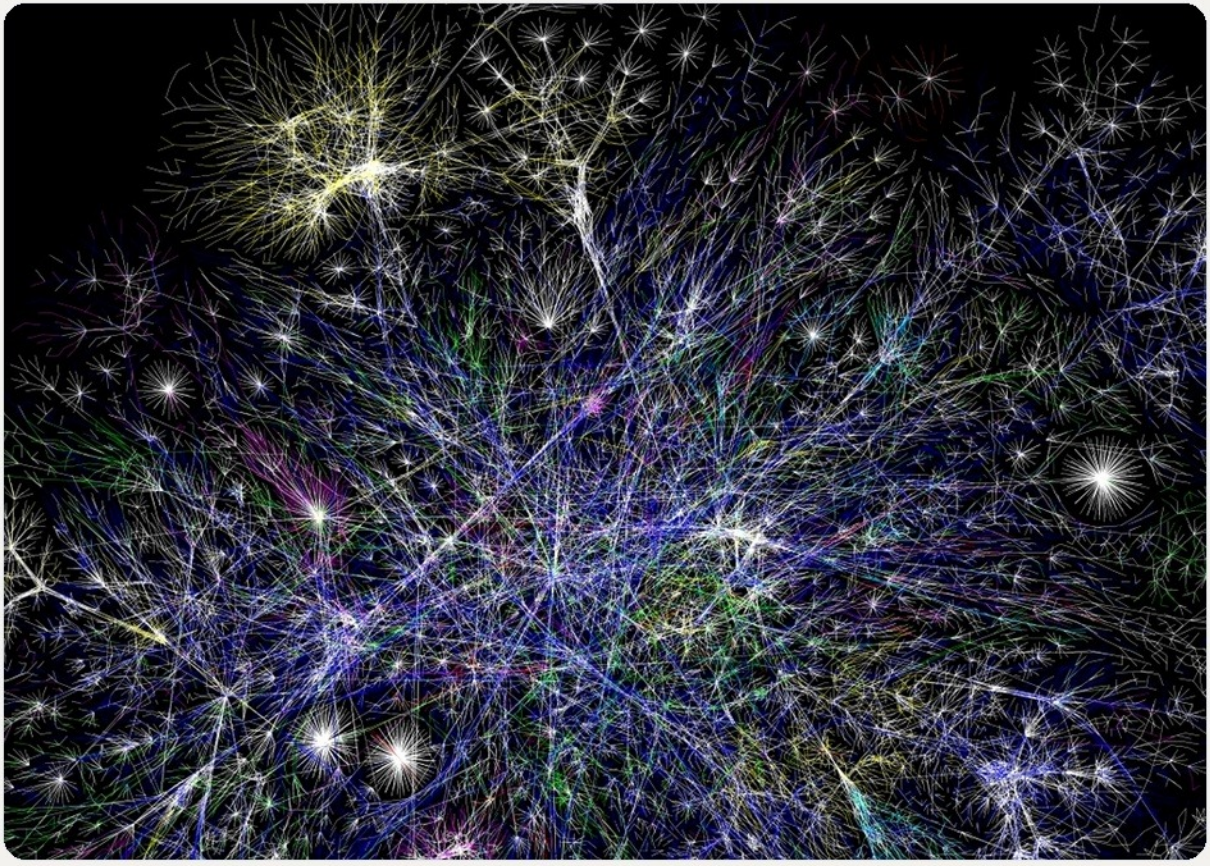
- **MITO:** Colar tudo em **1 milhão de tokens** acaba com alucinações.
- **FATO:** Aumenta o **Context Rot** e gera o efeito 'Lost in the Middle'.
- **MITO:** Plugou banco vetorial, **o dado está seguro.**
- **FATO:** Sem checagem de acesso **antes do prompt,** o modelo vaza sigilos.
- **MITO:** Basta melhorar o prompt para **corrigir erros.**
- **FATO:** Sem governança de dados, o modelo só **articula melhor o erro.**



Ismael Soilet
@ismaelsoilet

GRAPHRAG: LIGANDO OS PONTOS COM RIGOR TOPOLÓGICO

- **MAPA ESTRUTURADO:** Extrai entidades — **Leis, Clientes e Cláusulas** — e suas conexões reais.
- **MULTI-HOP:** Responde como uma regra fiscal **impacta contratos em cascata** entre áreas.
- **TRAVA ANTI-ALUCINAÇÃO:** Se não há **caminho válido no grafo,** a IA não pode inventar pontes!



Ismael Soilet
@ismaelsoilet

LAZYGRAPHRAG: PRECISO COMO GRAFO, BARATO COMO VETOR

- **GARGALO ANTIGO:** O GraphRAG padrão custava até **1.000x mais** para indexar o acervo antes.
- **VIRADA LAZY:** Adia a leitura pesada com IA para **apenas na hora da pergunta.**
- **RESULTADO REAL:** Indexação no custo do **Vector RAG** e consulta global a **~4% do gasto** antigo.



Ismael Soilet
@ismaelsoilet

ADEUS SÓ PROMPT: BEM-VINDO AO CONTEXT ENGINEERING

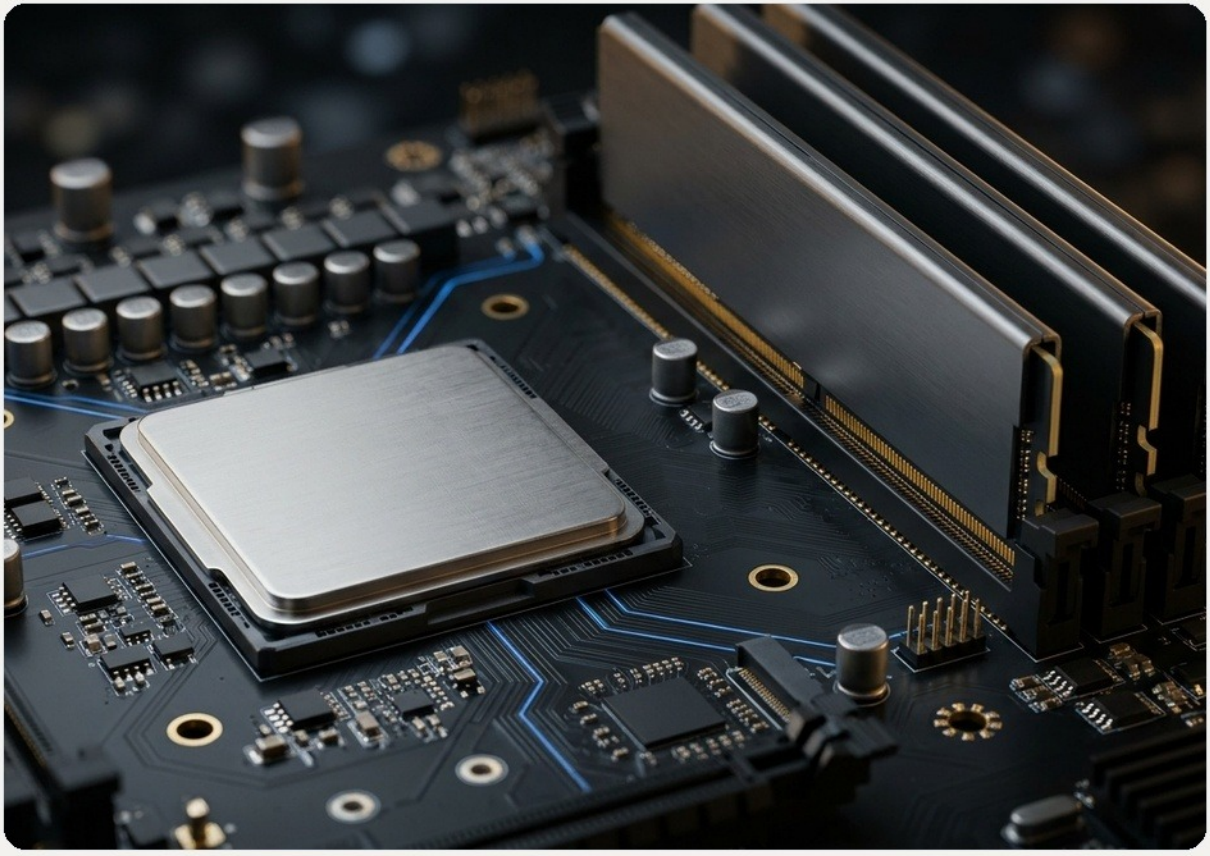
- **PROMPT ENGINEERING:** Foca apenas em **como você escreve a pergunta** no chat.
- **CONTEXT ENGINEERING:** Projeta o **ecossistema inteiro de dados** entregue em cada etapa.
- **VIRADA DE CHAVE:** Pare de caçar 'palavras mágicas' e construa **esteiras confiáveis.**



Ismael Soilet
@ismaelsoilet

ANALOGIA MESTRE: O LLM É A CPU; O CONTEXTO É A RAM

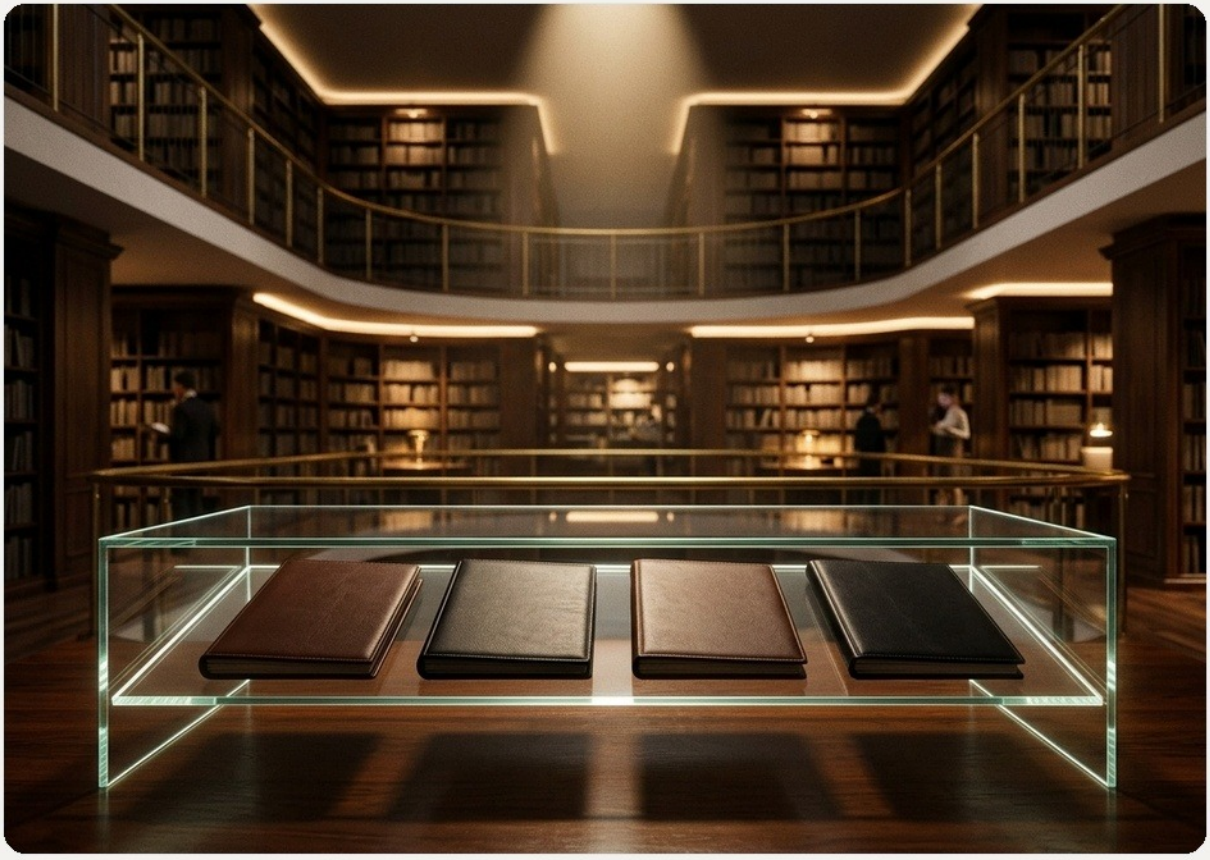
- PROCESSADOR (CPU): O modelo LLM é apenas o motor que **raciocina no ciclo atual.**
- **MEMÓRIA RAM:** A janela de contexto é o espaço nobre e limitado de **trabalho imediato.**
- **SISTEMA OPERACIONAL:** **Context Engineering** decide o que entra, sai e cabe na RAM!



Ismael Soilet
@ismaelsoilet

A BIBLIOTECA RASGADA VS. O BIBLIOTECÁRIO-CHEFE

- **VECTOR RAG:** Buscar palavras num índice remissivo de **páginas soltas e picotadas.**
- **GRAPHRAG:** O **mapa de cordas** conectando contratos, leis e prazos válidos.
- **CONTEXT ENGINEERING:** O **bibliotecário com crachá** que barra arquivos velhos ou sigilosos!



Ismael Soilet
@ismaelsoilet

OS 4 PILARES DA ENGENHARIA DE CONTEXTO

1. **WRITE:** Gravar memórias e estados fora da janela para **não poluir o prompt.**
2. **SELECT:** Buscar com **ACL em tempo real,** filtro temporal e Reranking cirúrgico.
3. **COMPRESS:** Resumir históricos e podar JSONs para **frear o Context Rot.**
4. **ISOLATE:** Separar **agentes especializados** em contextos blindados e limpos.



Ismael Soilet
@ismaelsoilet

CHECKLIST: COMO BLINDAR A IA NA SUA OPERAÇÃO

1. **ACL PRÉ-PROMPT:** Valide permissões do usuário **antes** de enviar trechos ao LLM.
2. **TEMPORALIDADE:** Marque **início e fim de vigência** em cada norma e contrato.
3. **ORDEM EM U:** Coloque os trechos mais confiáveis **no início e no fim** do contexto.



Ismael Soilet
@ismaelsoilet

SÍNTESE: A IA SÓ É INTELIGENTE NO CONTEXTO CERTO

SALVAR: Guarde este mapa de **RAG, GraphRAG e Context Engineering** para seus projetos.

COMPARTILHAR: Envie para CTOs, devs e líderes antes do próximo piloto de IA.

COMENTAR: Na sua empresa, a IA já sofreu com dado velho ou sem permissão?

CURTIR: Apoie a série e siga @ismaelsoilet para o Episódio 04 (IA na Receita Federal)!

