Ismael Soilet
@ismaelsoilet

SLMS E TOKENOMICS: A CONTA OCULTA DA IA

Você está pagando um modelo de 1 trilhão de parâmetros para tarefas simples? Entenda a revolução dos **Small Language Models** e do **Edge AI** — e como empresas cortam **até 90% do custo** de inferência



Ismael Soilet
@ismaelsoilet

O CHOQUE DO CFO: 4 EM CADA 5 DÓLARES SEM ROI

- **FATURA DA NUVEM:** 80% dos gastos em tokens de nuvem **não comprovam retorno claro** (Accenture/Gartner).
- **TRAVA NO BRASIL:** 35% das empresas já paralisam pilotos por **imprevisibilidade de custos** (Dell/IDC).
- **ESCALABILIDADE:** O consumo de tokens deve crescer **93% no próximo ano,** exigindo FinOps rígido.





Ismael Soilet
@ismaelsoilet

A FALÁCIA DO GIGANTE: CANHÃO PARA MATAR MOSQUITO

- **O SUPERMODELO:** Treinado sobre petabytes com **1T+ de parâmetros** e custo massivo de GPUs.
- **A TAREFA REAL:** Extrair 4 campos de uma nota fiscal ou **classificar um chamado de suporte.**
- **INEFICIÊNCIA:** Usar supercomputação global para rotinas mecânicas **queima margem de lucro a cada clique.**



Ismael Soilet
@ismaelsoilet

A REALIDADE CORPORATIVA: 85% DAS TAREFAS SÃO DIRECIONADAS

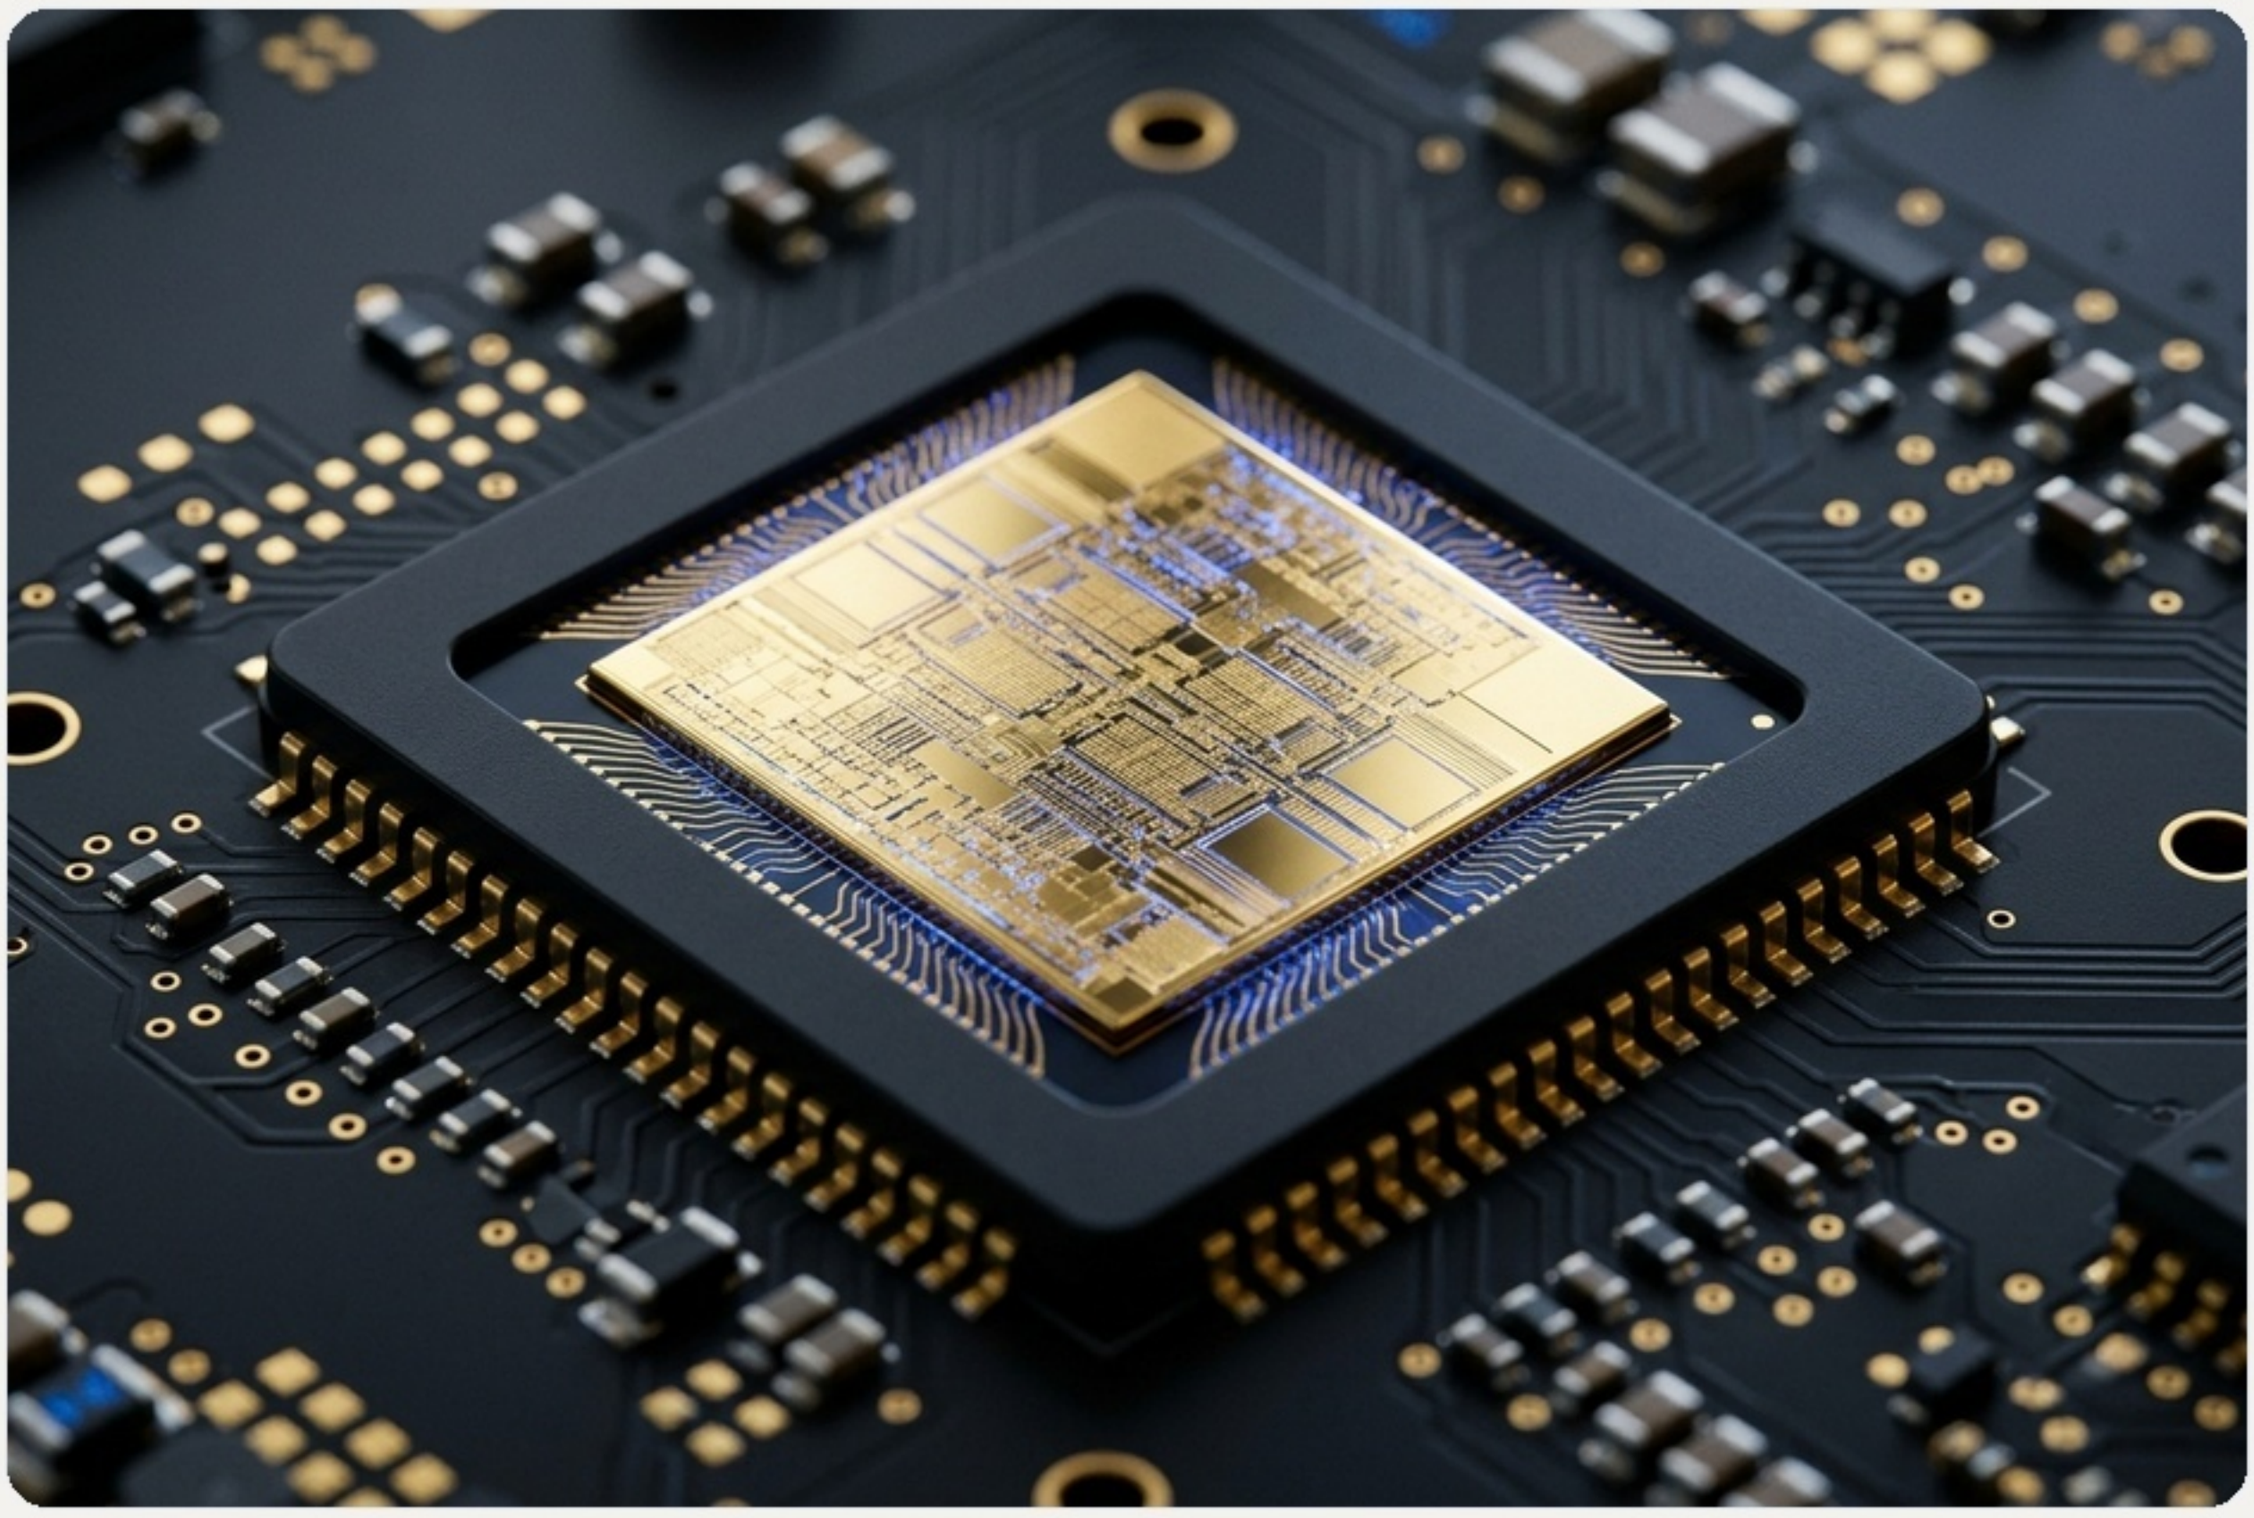
- **FLUXOS ESTRUTURADOS:** Extração de JSON, triagem de petições, **validação de políticas e resumos.**
- **FOCO CIRÚRGICO:** Nenhuma dessas demandas exige que o modelo conheça **poesia ou astronomia.**
- **OPORTUNIDADE:** Modelos compactos focados no seu domínio entregam **resultados mais rápidos e consistentes.**



Ismael Soilet
@ismaelsoilet

O QUE SÃO OS SLMS? EFICIÊNCIA DE 1B A 14B

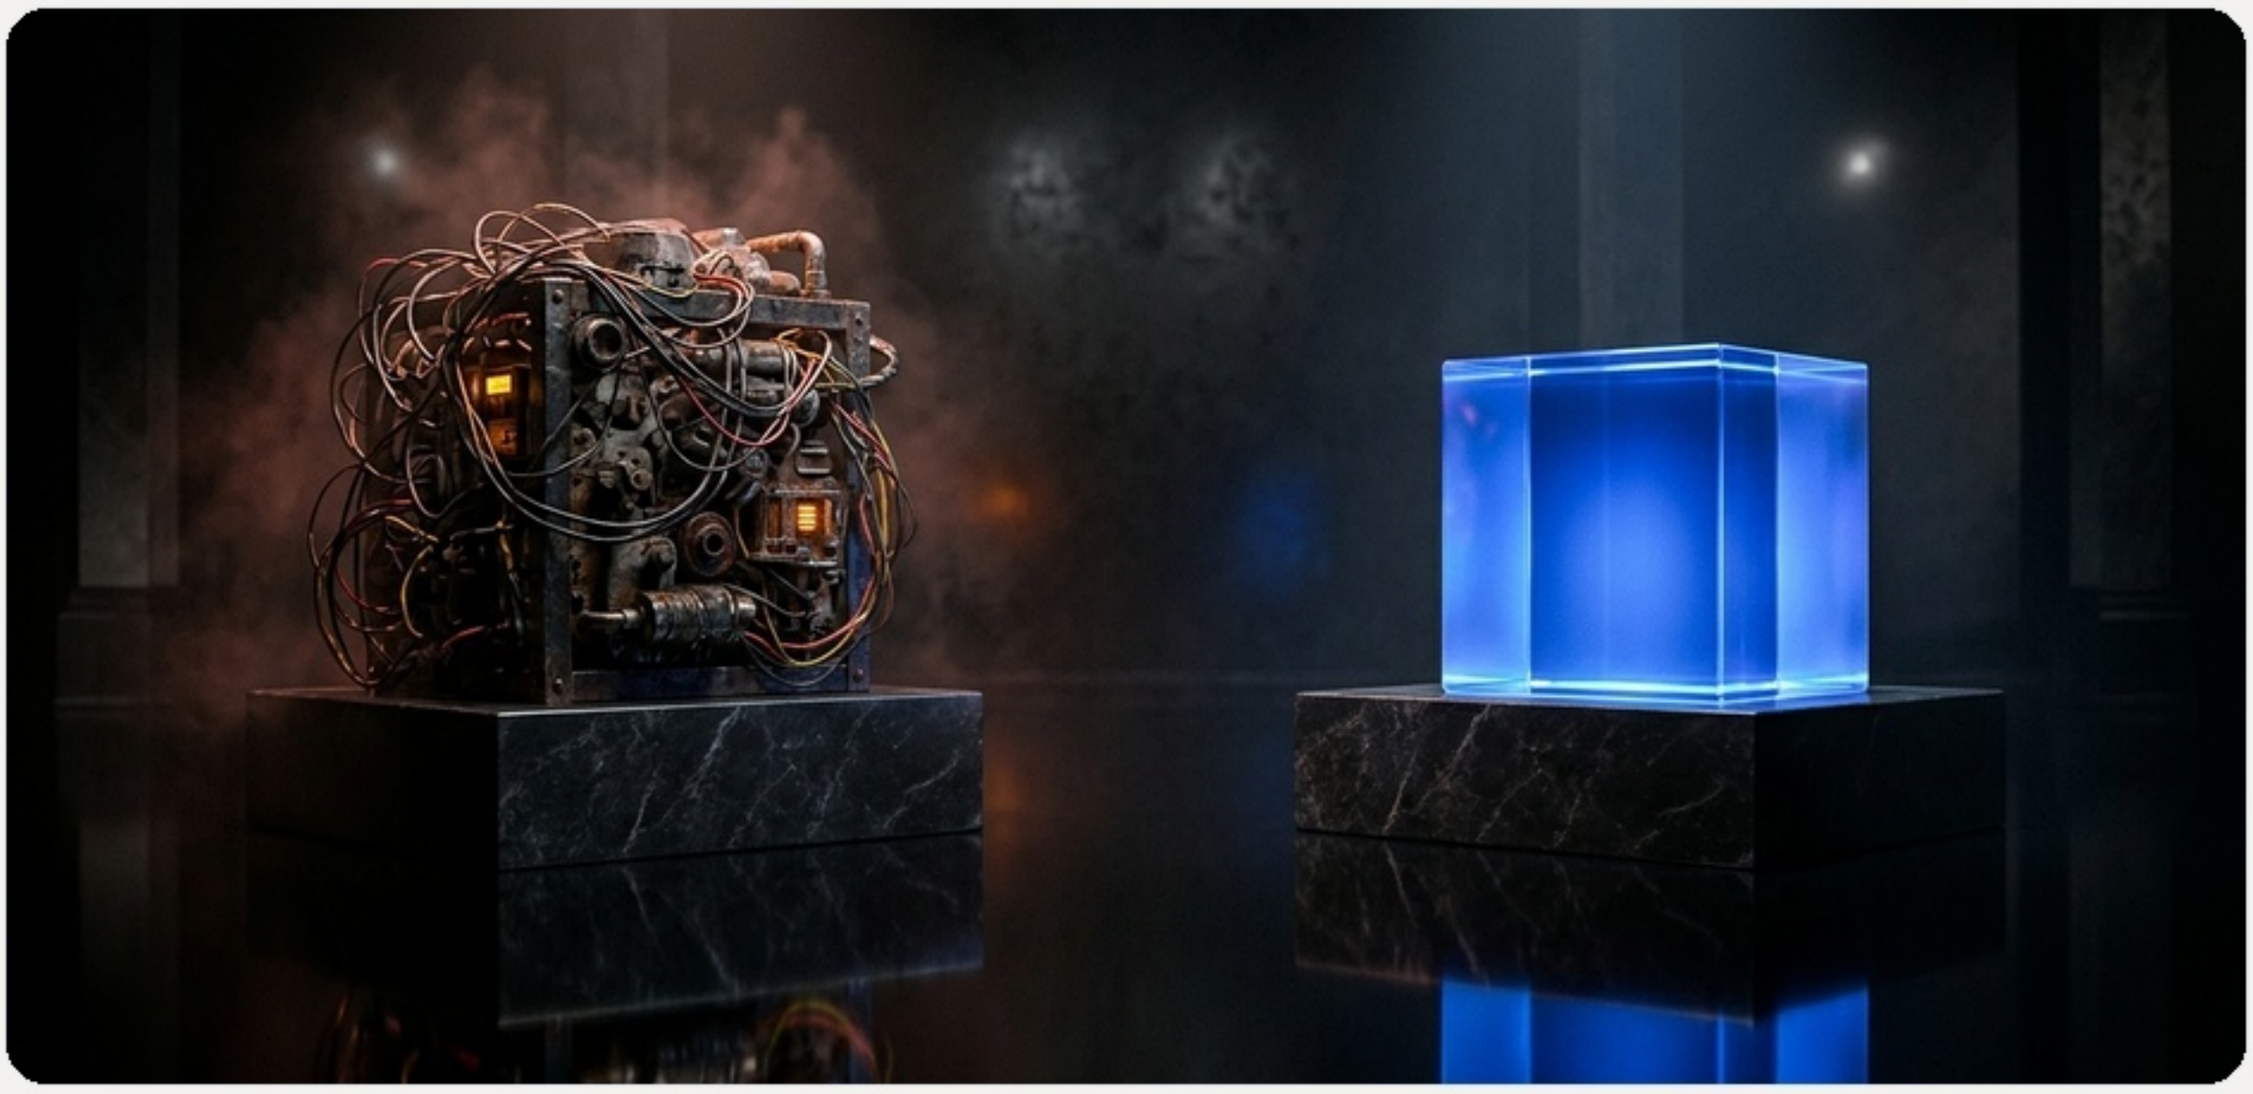
- **SMALL LANGUAGE MODELS:** Modelos compactos como **Llama 3.2, Qwen 2.5, Phi-4 Mini e Gemma 2.**
- **PESO COMPUTACIONAL:** Até **100 vezes menores** que os gigantes de fronteira.
- **DESEMPENHO:** Raciocínio lógico refinado e capacidade de **rodar em servidores locais e computadores comuns.**



Ismael Soilet
@ismaelsoilet

MATRIZ DE VERDADE: SLMS VS. LLMS GIGANTES

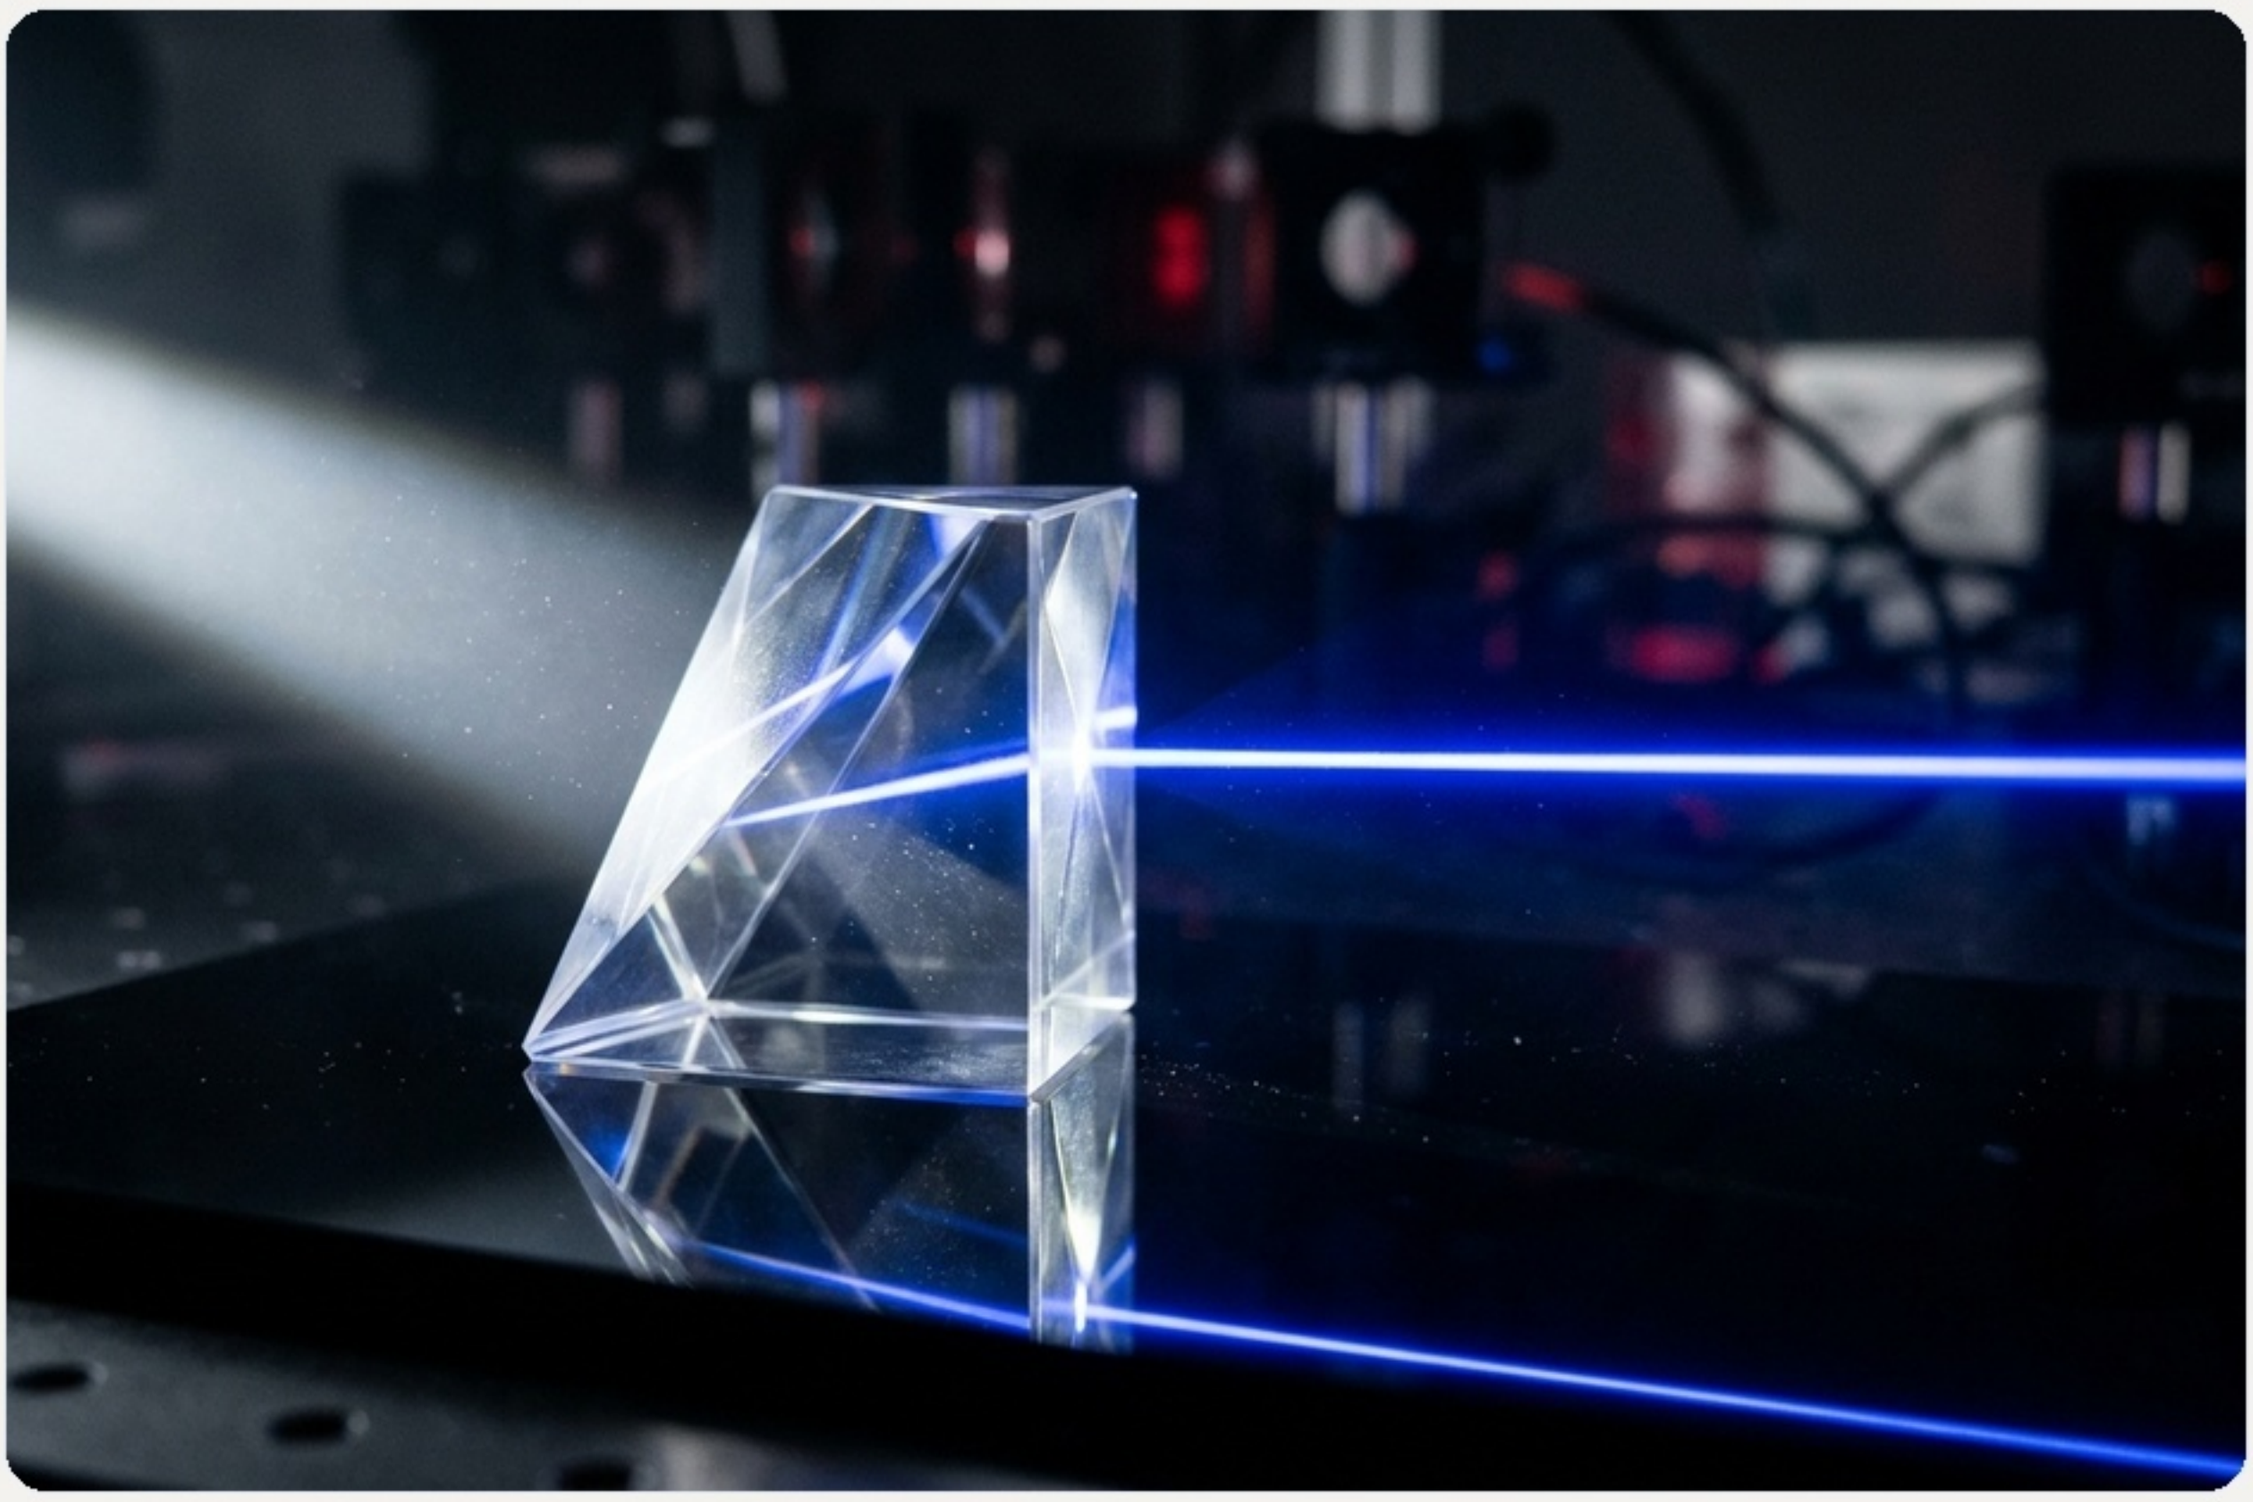
- **MITO:** Modelo pequeno é burro e **não serve para empresas.**
- **FATO:** Ajustado ao domínio, atinge **acurácia > 98%** em tarefas específicas.
- **MITO:** Rodar na nuvem pública é sempre **mais barato.**
- **FATO:** Em escala contínua, o custo por token **destrói a margem do produto.**
- **MITO:** Precisa de datacenter milionário para **rodar IA local.**
- **FATO:** Modelos quantizados rodam em **servidores comuns ou PCs com NPU.**



Ismael Soilet
@ismaelsoilet

O SEGREDO TÉCNICO: DESTILAÇÃO E QUANTIZAÇÃO

- **DESTILAÇÃO:** O modelo gigante ensina o pequeno, gerando **dados sintéticos de altíssima densidade.**
- QUANTIZAÇÃO (INT4/INT8): Reduz pesos de 16 para 4 bits, cortando **75% da VRAM sem perder precisão.**
- FINE-TUNING (LoRA): Especialização profunda no vocabulário **jurídico, tributário ou operacional da empresa.**



Ismael Soilet
@ismaelsoilet

A MATEMÁTICA DOS CUSTOS: ATÉ 90% DE ECONOMIA

- 500K CHAMADAS/MÊS: Custo de **R$ 20.000 a R$ 35.000** em APIs de nuvem de fronteira.
- SLM LOCAL (EDGE): Custo marginal **próximo a zero** após a amortização do hardware.
- **SEM RISCO CAMBIAL:** Fim da fatura atrelada ao dólar e **eliminação de taxas de tráfego de saída.**



Ismael Soilet
@ismaelsoilet

EDGE AI E SOBERANIA: DADOS NUNCA SAEM DE CASA

- **BLINDAGEM REGULATÓRIA:** Dados fiscais, contratos e informações de clientes **nunca saem da sua rede.**
- **SOBERANIA DIGITAL:** Alinhamento com o **Acórdão 1.380/2026 do TCU** e as normas da Portaria RFB 647.
- **ZERO COMPARTILHAMENTO:** Conformidade rigorosa com a **LGPD e sigilo empresarial irrestrito.**



Ismael Soilet
@ismaelsoilet

LATÊNCIA EM TEMPO REAL: DE SEGUNDOS PARA <100MS

- **FILAS DE NUVEM:** Espera de **2 a 5 segundos** por resposta inviabiliza processos críticos.
- **RESPOSTA INSTANTÂNEA:** No Edge local, a inferência responde entre **40ms e 90ms.**
- **EXPERIÊNCIA FLUIDA:** O usuário ou sistema parceiro percebe a automação **como tempo real absoluto.**

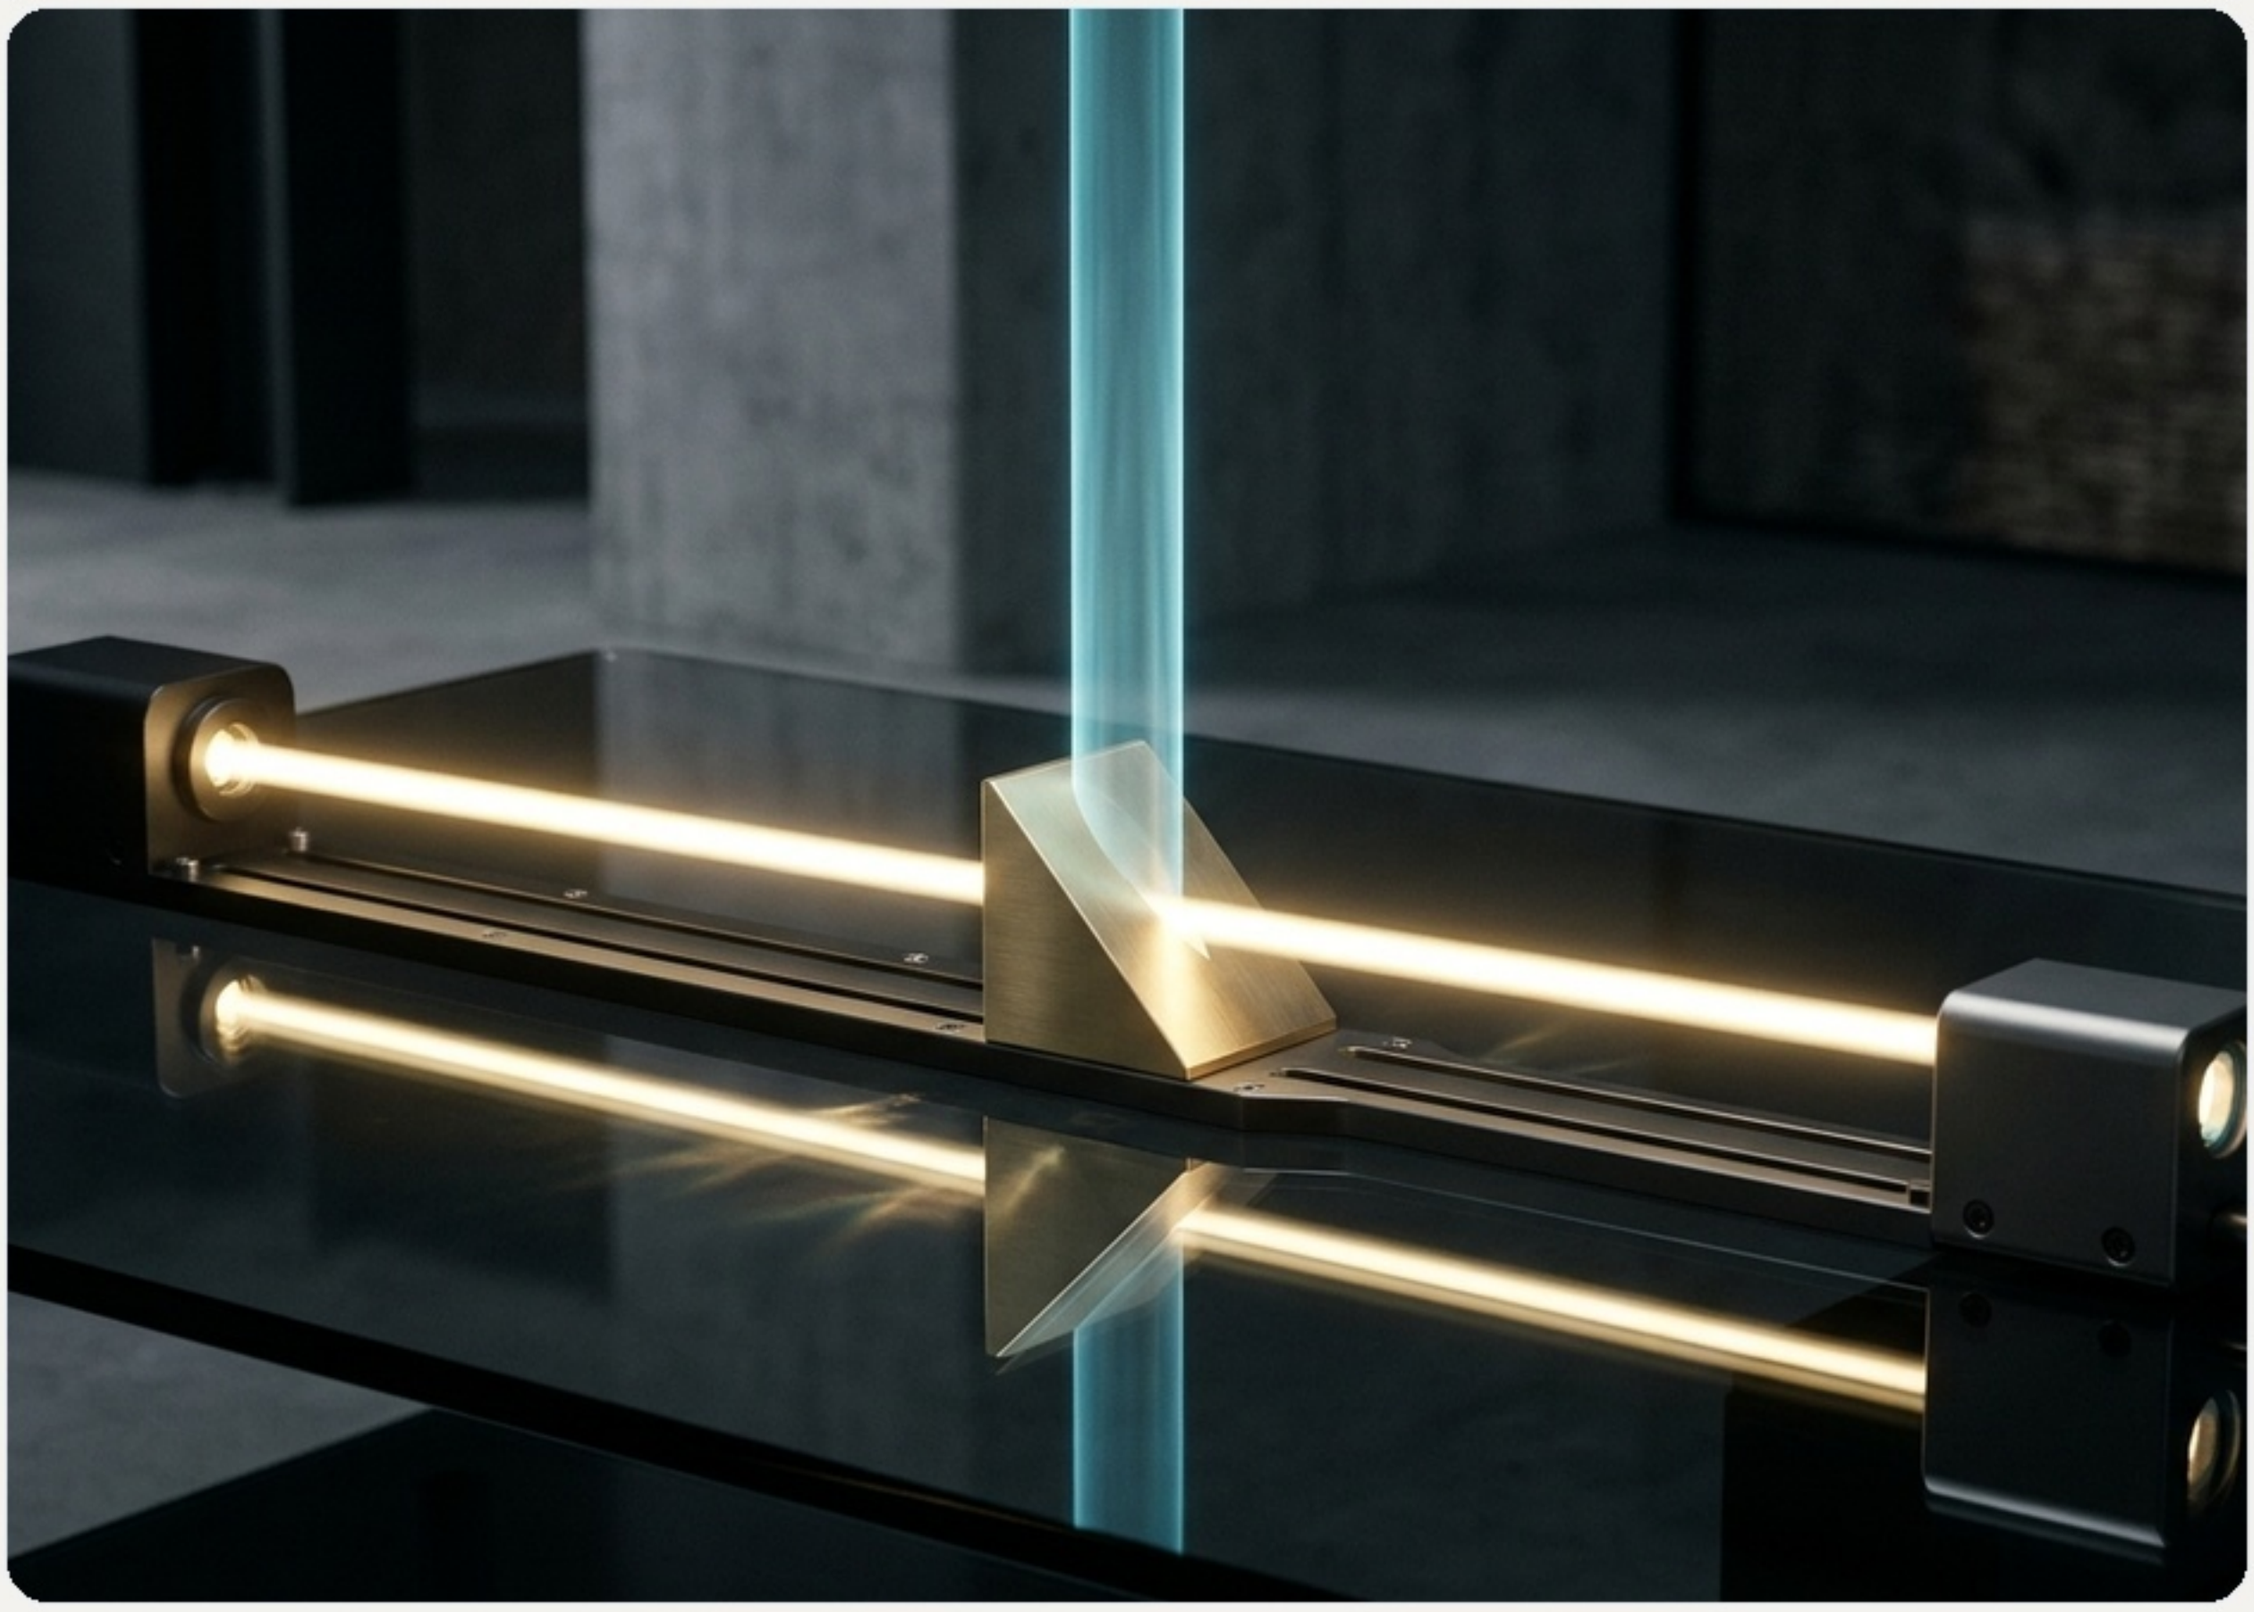




Ismael Soilet
@ismaelsoilet

ARQUITETURA HÍBRIDA: TRIAGE-AND-ESCALATE

- **ROTEADOR SEMÂNTICO:** Um classificador avalia a complexidade de cada **requisição na entrada.**
- 85% NA BORDA: O SLM local resolve a grande maioria das rotinas **a custo zero e latência mínima.**
- 15% NA NUVEM: Apenas casos de alta ambiguidade ou raciocínio complexo **escalam para o LLM de fronteira.**





Ismael Soilet
@ismaelsoilet

IMPACTO CORPORATIVO:
PREVISIBILIDADE E ESCALA

- **ESCALABILIDADE REAL:** Sua base de usuários pode dobrar **sem dobrar a fatura de tecnologia.**
- **RESILIÊNCIA TOTAL:** A operação continua funcionando mesmo se **a internet internacional oscilar.**
- **FINOPS SUSTENTÁVEL:** Investimento em infraestrutura própria **com retorno visível para a diretoria.**



Ismael Soilet
@ismaelsoilet

CHECKLIST EXECUTIVO: COMO CORTAR CUSTOS DE IA

1. AUDITORIA DE FINOPS: Mapeie quais sistemas usam **modelos gigantes sem necessidade real.**
2. ADOTE SLMS NA BORDA: Troque chamadas de rotina por **modelos locais de 7B a 14B parâmetros.**
3. IMPLEMENTE ROTEAMENTO: Crie a barreira **Triage-and-Escalate antes de qualquer chamada em nuvem.**





Ismael Soilet
@ismaelsoilet

SÍNTESE: INTELIGÊNCIA É RESOLVER COM O MENOR CUSTO

🔖 **SALVAR:** Guarde este guia de **SLMs, Tokenomics e Edge AI** para a estratégia da sua empresa.

🔗 **COMPARTILHAR:** Envie para CFOs, CTOs e líderes de tecnologia antes do próximo orçamento.

💬 **COMENTAR:** Na sua organização, os custos com tokens de IA já viraram pauta da diretoria?

❤️ **CURTIR:** Apoie esta série e siga @ismaelsoilet para o Episódio 06 (Cases e Soberania Digital)!

